

WikiRAG-TR Üzerinde Türkçe RAG Sistemi

Retrieval-Augmented Generation: Tasarım, Advanced RAG Deneyleri, Değerlendirme, Güvenlik ve Gözlemlenebilirlik

Alan	Final durum
Veri seti	Metin/WikiRAG-TR
Ana corpus	5.723 benzersiz doküman
Final retrieval	Fixed-size + Dense/BM25 Hybrid + RRF
Embedding	paraphrase-multilingual-MiniLM-L12-v2
Generation	Qwen/Qwen2.5-1.5B-Instruct
Vector DB	FAISS
Observability	Arize Phoenix + OpenTelemetry

Temel bulgu: Retrieval katmanı güçlü sonuçlar üretirken generation kalitesi ve özellikle generation latency sistemin ana darboğazıdır.

1. Problem ve Veri Seti Seçimi

Amaç, kullanıcı sorularına kaynak göstererek cevap veren; desteklenmeyen sorularda cevap vermekten kaçınabilen; retrieval ve generation katmanları ayrı ayrı ölçülebilen bir Türkçe RAG sistemi geliştirmektir.

Track A kapsamında WikiRAG-TR seçilmiştir. Hazır ground-truth, negatif örnekler ve Türkçe genel bilgi içeriği retrieval değerlendirmesini doğrudan ölçülebilir hale getirmiştir. Sadece verilen bağlam kullanılmamış, tüm makalelerin birleşiminden 5.723 benzersiz dokümanlık corpus oluşturulmuştur.

1.1 Multi-format ingestion

Ana benchmark 5.723 WikiRAG-TR kaydı üzerinde dondurulmuştur. Çoklu format ingestion desteğini göstermek için ayrıca proje tarafından oluşturulan bir Markdown dokümanı okunmuş ve ayrı bir multi-format ingestion testinde toplam 5.724 kayıt elde edilmiştir. Bu ek doküman, daha önce ölçülmüş benchmark sonuçlarını değiştirmemek için retrieval deneylerine sonradan dahil edilmemiştir.

Ham veri repository içinde tutulmaz; veri seti scripts/download_data.py üzerinden load_dataset('Metin/WikiRAG-TR') ile yeniden elde edilebilir. README içinde kaynak/lisans notu yer almaktadır.

2. Veri Hazırlama ve Chunking

Üç chunking yaklaşımı test edilmiştir: fixed-size + overlap, RecursiveCharacterTextSplitter ve Parent-Child yaklaşımı. Final sistemde fixed-size chunking seçilmiştir.

Yaklaşım	Chunk sayısı	Ortalama uzunluk	Recall@5	MRR@10
Fixed-size	11.619	362.006 karakter (güncel histogram)	0.90	0.8347
Recursive	12.718	~319.26 karakter	0.86	0.8358
Parent-Child	24.026 child / 5.723 parent	~169.28 karakter	0.86	0.7290

Fixed-size chunklarda gözlenen minimum uzunluk 1, maksimum 500 ve ortalama 362.006 karakterdir. Notebook'ta chunk uzunluk histogramı üretilmiştir.

Her baseline chunk için source, doc_title, section, page, chunk_id, created_at, lang metadata alanları eklenmiştir. Kaynakta bulunmayan doc_title/section/page alanları uydurulmamış ve None bırakılmıştır.

3. Baseline ve Final Retrieval

Sürüm	Recall@3	Recall@5	Recall@10	MRR@10	nDCG@10
V0 Dense	0.86	0.90	0.92	0.8347	0.8294
V1 Hybrid (Dense+BM25+RRF)	0.96	1.00	1.00	0.9200	0.9443
V2 + Cross-Encoder	0.96	0.98	0.98	0.9083	Ölçülmedi

Hybrid Search, dense baseline'a göre belirgin retrieval kazanımı sağlamıştır. Cross-Encoder reranking ise ek hesaplama yüküne rağmen Hybrid sonucu geliştirmemiştir; bu negatif sonuç korunmuş ve final pipeline'a reranker eklenmemiştir.

4. Güncel 60 Soruluk Değerlendirme Seti

Değerlendirme seti 60 sorudan oluşur: 20 factual, 15 multi-hop, 10 comparison, 8 ambiguous ve 7 unanswerable. 30 soru kullanıcı tarafından kendi cümleleriyle manuel olarak yazılmıştır; böylece setin en az yarısının manuel olması şartı karşılanmıştır.

Kategori	Sayı	Recall@3	Recall@5	Recall@10	MRR@10	nDCG@10
Factual	20	1.0000	1.0000	1.0000	0.9500	0.9631
Multi-hop	15	0.7667	0.8444	0.8667	0.9429	0.8461
Comparison	10	0.9000	0.9500	0.9500	0.8000	0.8344
Ambiguous	8	0.1875	0.1875	0.2500	0.1875	0.1875

Kategori	Sayı	Recall@3	Recall@5	Recall@10	MRR@10	nDCG@10
Tüm cevaplanabilir	53	0.7925	0.8239	0.8396	0.8046	0.7886

En önemli yeni bulgu, açık factual sorularda retrieval'in çok güçlü; bağlamı eksik/ambiguous sorularda ise belirgin biçimde zayıf olmasıdır. Bu sonuç query understanding ve disambiguation ihtiyacını göstermektedir.

4.1 Cevaplanamaz sorular

Metrik	Sonuç
Toplam unanswerable	7
Doğru abstention	5
False answer	2
Abstention Rate	0.7143
False Answer Rate	0.2857

Sistem cevaplanamaz soruların çoğunda doğru şekilde cevap vermekten kaçınmış olsa da false answer oranı sıfır değildir. Bu nedenle grounding/abstention katmanı production için geliştirilmelidir.

5. Advanced RAG Teknikleri

Projede ödev menüsünde yer alan dört teknik uygulanmıştır: Hybrid Search (BM25 + dense + RRF), Cross-Encoder Reranking, Parent-Document Retrieval ve Query Decomposition. Ödev metni en az bir tekniğin 'Zor' gruptan olmasını ister; ancak sağlanan metin tekniklerin hangisinin Zor olarak etiketlendiğini ayrıca göstermemektedir. Bu nedenle raporda herhangi bir tekniğe doğrulanmamış 'Zor' etiketi verilmemiştir.

Query Decomposition multi-hop soruları alt sorulara bölmek için denenmiştir. Retrieval tarafında yararlı örnekler üretmesine karşın küçük generation modeli bazı testlerde kaynak dışı ayrıntı üretmiştir. Bu da retrieval iyileştirmesinin generation doğruluğunu otomatik olarak garanti etmediğini göstermiştir.

6. Generation Kalitesi

Metrik	Skor
Faithfulness	0.4650
Answer Correctness	0.4220
Answer Relevancy	0.2100
Context Recall	1.0000
Basitleştirilmiş Context Precision	0.3200

Bu generation skorları 10 soruluk küçük bir alt kümede aynı Qwen modelinin judge olarak kullanıldığı ön değerlendirmeden gelmektedir. Context Precision standart RAGAS metriği değil, relevant_doc_id tabanlı basitleştirilmiş bir ölçümdür. Bu sınırlamalar nedeniyle skorlar kesin kalite ölçümü olarak değil, ön değerlendirme olarak yorumlanmalıdır.

7. Latency ve Production Hedefi

Katman	P50	P95	Ortalama / not
Hybrid retrieval (20 soru)	0.1727 sn	0.5877 sn	0.2318 sn
Generation (5 factual soru)	257.9184 sn	308.0800 sn	268.4314 sn

Retrieval P95 değeri bir saniyenin altındadır; generation P95 ise yaklaşık 5 dakika 8 saniyedir. Dolayısıyla sistem brief'teki 5 saniyelik toplam cevap hedefini karşılamamaktadır. Ana latency darboğazı retrieval değil generation katmanıdır. Daha hızlı model, quantization, optimized inference ve uygun GPU altyapısı

production için temel iyileştirme alanlarıdır.


8. Güvenlik ve Grounding

Korpuse önceki talimatları yok saymayı amaçlayan kontrollü bir prompt-injection dokümanı eklenmiştir. Kaynak içindeki komutların yalnızca veri olarak ele alınması gerektiği promptta belirtilmiştir. Model saldırı talimatını uygulamamış ve sistem mesajını açığa çıkarmamıştır; ancak aynı test generation relevancy probleminin sürdüğünü göstermiştir.

Bu tek bir kontrollü saldırı örneğidir; kapsamlı red-team testi değildir.

9. Observability - Arize Phoenix

Arize Phoenix ve OpenTelemetry kullanılarak Hybrid retrieval işlemi trace edilmiştir. Trace'e kullanıcı sorusu, retrieval yöntemi, top-k, retrieval latency ve getirilen document ID'leri attribute olarak kaydedilmiştir.



Şekil 1. Arize Phoenix içinde hybrid_retrieval trace'i ve RAG attribute'ları.

Bu ekran, pipeline sorgularının gözlemlenebilir olduğunu ve retrieval adımının ayrı bir span olarak izlenebildiğini göstermektedir.

10. Maliyet Projeksiyonu

Bileşen	Teknoloji	1.000 sorgu doğrudan API maliyeti
Embedding	paraphrase-multilingual-MiniLM-L12-v2	\$0
Generation	Qwen/Qwen2.5-1.5B-Instruct	\$0
Vector DB	FAISS	\$0
Lexical retrieval	rank_bm25	\$0
Toplam	-	\$0 / 1.000 sorgu

Bu değer yalnızca doğrudan API/yazılım maliyetidir. Production ortamında GPU/CPU compute, RAM, depolama, ağ, monitoring ve operasyon maliyetleri oluşur. Bu nedenle toplam sahip olma maliyeti sıfır değildir.

11. Ablation ve Negatif Sonuçlar

Sürüm	Değişiklik	Recall@5	nDCG@10	MRR@10
V0	Dense baseline	0.90	0.8294	0.8347
V1	+ BM25 + RRF Hybrid	1.00	0.9443	0.9200
V2	+ Cross-Encoder Reranking	0.98	Ölçülmedi	0.9083
V3	Parent-Child Retrieval	0.86	Ölçülmedi	0.7290
V4	Query Decomposition	Deneysel	Ölçülmedi	Ölçülmedi

Negatif sonuçlar özellikle korunmuştur: Cross-Encoder reranking Hybrid sistemi geliştirmede; Parent-Child retrieval geriledi; similarity threshold deneyi çok sayıda cevaplanabilir soruyu yanlış abstain etti; Query Decomposition retrieval tarafında yararlı olsa da generation hatalarını ortadan kaldırmadı.

12. Hata Analizi

Baseline ve retrieval analizinde hatalar iki sınıfa ayrılmıştır: retrieval hataları ve generation hataları. Retrieval tarafında genel veya yüzeysel olarak benzer dokümanların daha spesifik doğru dokümanın önüne geçebildiği örnekler gözlenmiştir. Hybrid Search bu sorunu önemli ölçüde azaltmıştır.

Generation tarafında ise doğru kaynak ilk sırada bulunsa dahi modelin yanlış veya ilgisiz cevap üretebildiği görülmüştür. Bu, projenin en önemli mimari sonucudur: doğru retrieval tek başına doğru generation garantisi değildir.

13. Mimari Karar ve Repo Yapısı

Final karar ADR-001 içinde belgelenmiştir: Fixed-size chunking + Dense/BM25 Hybrid Retrieval + RRF + top-5 kaynak-temelli generation. Reranker final sisteme alınmamıştır.

Repository; README.md, requirements.txt, notebook/, eval/eval_set_v2.json, scripts/download_data.py, docs/architecture.md, docs/adr/ADR-001-hybrid-retrieval.md ve report/ bileşenlerini içerecek şekilde düzenlenmiştir.

14. Sınırlamalar ve Production Gap'leri

Başlıca sınırlamalar: generation değerlendirmesinin küçük alt kümede yapılması; aynı modelin üretici ve judge olması; bazı ablation satırlarında tüm generation metriklerinin ayrı ayrı yeniden ölçülmemesi; Colab latency değerlerinin production benchmark olmaması; tek prompt-injection testinin kapsamlı güvenlik değerlendirmesi sayılmaması.

Production için ölçeklenebilirlik, veri güncelleme/yeniden indeksleme, model serving, monitoring, human feedback, daha güçlü abstention/grounding, bağımsız evaluator ve latency optimizasyonu gereklidir.

15. Sonuç

WikiRAG-TR üzerinde ölçülebilir bir Türkçe RAG pipeline'ı kurulmuştur. En güçlü retrieval sonucu Dense ve BM25'in RRF ile birleştirildiği Hybrid Search'ten gelmiştir. Güncel 60 soruluk eval setinde factual sorular çok güçlü, ambiguous sorular ise belirgin biçimde zayıf retrieval performansı göstermiştir.

Final sistemin ana problemi generation katmanıdır: kalite skorları sınırlı ve generation P95 308.08 saniyedir. Bu nedenle proje yalnızca çalışan bir chatbot değil, hangi katmanın neden iyileştirilmesi gerektiğini ölçümlerle gösteren bir RAG mimarisi ortaya koymaktadır.